

İTÜ Rover
Teknik Dokümantasyon:
RF-DETR Seg, Depth Anything v2 ve MiDaS

Hazırlayan: Mert Efe Demir

13.11.2025

İçindekiler

1	Giriş	2
2	RF-DETR Seg	2
2.1	Genel Mimari	2
2.2	Region-Free Query Mekanizması	2
2.3	Transformer Encoder	2
2.4	Transformer Decoder	3
2.5	Dinamik Segmentasyon Başlığı	3
3	Depth Anything v2	3
3.1	Genel Mimari	3
3.2	Derinlik Tahmin Formulasyonu	3
3.3	Multi-Scale Decoder	4
4	MiDaS	4
4.1	Genel Bakış	4
4.2	DPT Encoder	4
4.3	Relative Depth Normalization	4
5	Karşılaştırmalı Teknik Analiz	5
6	Birleşik Pipeline	5
6.1	Önerilen Algoritma	5

1 Giriş

Bu doküman, RF-DETR Seg, Depth Anything v2 ve MiDaS modellerinin teknik mimarilerini ayrıntılı olarak açıklamayı amaçlar. İçerik; transformer tabanlı nesne tespiti, mask tabanlı segmentasyon ve monocular derinlik tahmini konularında ileri seviye teorik bilgiler içermektedir.

2 RF-DETR Seg

2.1 Genel Mimari

RF-DETR Seg, **DETR (Detection Transformer)** mimarisinin bir varyantıdır ve aşağıdaki temel bileşenlerden oluşur:

1. **Backbone Encoder** — ResNet, Swin, ConvNeXt
2. **Transformer Encoder**
3. **Transformer Decoder**
4. **Query Embeddings (Region-Free)**
5. **Segmentation Head (Dynamic Mask Head)**

Bu yapı klasik CNN tabanlı tespit modellerinin aksine, anchor kutuları, bölge öneri ağları veya NMS (Non-Max Suppression) kullanmadan çalışır.

2.2 Region-Free Query Mekanizması

RF-DETR’de kullanılan sorgular, önceden tanımlı anchor kutularına bağlı değildir. Her bir sorgu yüksek boyutlu bir vektör:

$$q_i \in R^d$$

şeklinde ve bu vektörler görüntünün uzamsal yapısına göre değil, öğrenilmiş anlamsal ilişkiler üzerinden güncellenir.

2.3 Transformer Encoder

Encoder, backbone çıktısını

$$F \in R^{H \times W \times C}$$

olarak alır ve çoklu başlıklı self-attention üzerinden işler:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V.$$

Encoder’ın görevi, görüntü içindeki uzun menzilli bağımlılıkları modellemektir.

2.4 Transformer Decoder

Decoder, öğrenilmiş sorguları kullanarak görüntüdeki nesne adaylarını üretir:

$$z_i = \text{Decoder}(q_i, F).$$

Her bir z_i nesne sınıfı ve kutu parametrelerini verir:

$$\hat{b}_i = (x, y, w, h), \quad \hat{c}_i = \text{softmax}(W z_i).$$

2.5 Dinamik Segmentasyon Başlığı

Segmentasyon için RF-DETR, her sorgu için özel bir mask üretim ağı kullanır.

Mask üretilen tensör:

$$M_i = \sigma(g_i^\top E),$$

burada g_i sorgudan türetilen *dinamik filtre*, E ise backbone özellik haritasıdır.

Sonuç olarak her nesne için piksel seviyesinde maske elde edilir.

3 Depth Anything v2

3.1 Genel Mimari

Depth Anything v2, ViT tabanlı bir encoder ve çok ölçekli bir derinlik decoder'ından oluşur:

1. **ViT Encoder** (Large, Base, Small)
2. **Multi-scale Feature Fusion**
3. **Depth Regression Decoder**
4. **Depth Normalization Module**

3.2 Derinlik Tahmin Formulasyonu

Model, giriş görüntüsünü

$$I \in R^{H \times W \times 3}$$

olarak alır ve yoğun bir derinlik haritası üretir:

$$D \in R^{H \times W}, \quad D_{xy} > 0.$$

Üretilen derinlik genellikle doğrusal değil logaritmiktir:

$$D' = \log(D).$$

Bu, derinlik farklılıklarını daha istikrarlı hale getirir.

3.3 Multi-Scale Decoder

Derinlik decoder'ı FPN benzeri bir yapı kullanır:

$$F_{out} = \phi(F_1, F_2, F_3, F_4),$$

burada F_i encoder'ın farklı katmanlarından gelen özelliklerdir.

Bu özellikler birleştirilir ve derinlik regresyonuna gönderilir:

$$\hat{D} = W * F_{out}.$$

4 MiDaS

4.1 Genel Bakış

MiDaS, DPT (Dense Prediction Transformer) altyapısını kullanır.

4.2 DPT Encoder

DPT, Vision Transformer'ı aşağıdaki şekilde uyarlar:

$$z_0 = E(I), \quad z_{l+1} = \text{TransformerBlock}(z_l), \\ F = \text{Reshape}(z_L).$$

Burada z_l her bir transformer katmanını ifade eder.

4.3 Relative Depth Normalization

MiDaS mutlak (metrik) derinlik vermez. Normalizasyon:

$$D_{norm} = \frac{D - \min(D)}{\max(D) - \min(D)}.$$

Bu nedenle MiDaS çıktıları çoğunlukla *relatif sahne topolojisi* için uygundur.

Özellik	RF-DETR Seg	Depth Anything v2	MiDaS
Görev	Segmentasyon	Metrik derinlik	Relatif derinlik
Backbone	CNN / Swin	ViT-L/B/S	ViT-L/B
Çıktı	Maske + Kutu	Metrik derinlik	Normalize derinlik
Zero-shot Performans	Orta	Çok yüksek	Yüksek
Hesaplama Maliyeti	Yüksek	Çok yüksek	Orta

5 Karşılaştırmalı Teknik Analiz

6 Birleşik Pipeline

6.1 Önerilen Algoritma

Algorithm 1 Görüntüden 3B Anlamli Rekonstrüksiyon

Require: Görüntü I

- 1: $M, B, C \leftarrow RF-DETR(I)$
 - 2: $D \leftarrow DepthAnything(I)$
 - 3: **for** her nesne i **do**
 - 4: M_i maskesini uygula
 - 5: $D_i = D \odot M_i$
 - 6: **end for**
 - 7: **return** Nesne maskeleri, derinlik haritaları, 3B sahne yapısı
-

Bu yapı semantik + geometrik sahne analizi sağlar.